

MASTER DATA SCIENCE / INTELLIGENCE ARTIFICIELLE

Séries chronologiques

Théorie, modélisation et prévision

Chapitre 1

Introduction mathématique aux séries chronologiques

Principes mathématiques et statistiques
Applications et simulations en Python

Version imprimable - LaTeX

À propos de cette version

Cette édition est conçue pour l'impression et l'annotation. Elle reprend le contenu pédagogique du dépôt du cours et privilégie une typographie de manuel scientifique : équations lisibles, hiérarchie claire, encadrés pour définitions, propositions, preuves, exemples et avertissements, ainsi qu'une mise en page A4 sobre compatible avec l'impression couleur ou en niveaux de gris.

Table des matières

À propos de cette version	i
1 Introduction mathématique aux séries chronologiques	1
Fil conducteur du chapitre	1
1.1 Objectifs d'apprentissage	1
1.2 Qu'est-ce qu'une série chronologique ?	2
1.2.1 Définition	2
1.2.2 Pourquoi l'ordre compte-t-il ?	2
1.3 Temps discret, temps continu et irrégularité	3
1.3.1 Temps discret	3
1.3.2 Temps continu	4
1.3.3 Échantillonnage d'un phénomène continu	4
1.3.4 Séries irrégulièrement espacées	4
1.4 Fréquence, période, retard et horizon	4
1.4.1 Fréquence d'observation	4
1.4.2 Retard — lag	5
1.4.3 Horizon de prévision	5
1.5 Série observée et processus stochastique	5
1.5.1 Processus stochastique	6
1.5.2 Interprétation probabiliste	6
1.5.3 Une seule trajectoire : difficulté centrale	6
1.6 Décomposition déterministe et aléatoire	7
1.6.1 Composante déterministe	7
1.6.2 Composante aléatoire	7
1.7 Composantes classiques d'une série temporelle	7
1.7.1 Tendance	8
1.7.2 Saisonnalité	8
1.7.3 Cycle	9
1.7.4 Résidu	9
1.8 Décomposition additive et multiplicative	9
1.8.1 Modèle additif	9
1.8.2 Modèle multiplicatif	10
1.8.3 Transformation logarithmique	10
1.9 Pourquoi les observations temporelles ne sont-elles pas i.i.d. ?	11
1.9.1 Conséquence sur l'information statistique	11
1.10 Premières quantités probabilistes temporelles	11
1.10.1 Fonction moyenne	11
1.10.2 Variance	12
1.10.3 Autocovariance	12
1.10.4 Autocorrélation	12
1.11 Exemples mathématiques fondamentaux	12
1.11.1 Tendance déterministe + bruit centré	13

1.11.2	Saisonnalité déterministe + bruit	13
1.11.3	Variance croissante	13
1.11.4	Premier exemple de dépendance temporelle	14
1.11.5	Marche aléatoire — aperçu	14
1.12	Opérateur retard	14
1.12.1	Définition	14
1.12.2	Opérateur différence	15
1.12.3	Différence seconde d'un polynôme quadratique	15
1.13	La prévision comme problème conditionnel	16
1.13.1	Ensemble d'information	16
1.13.2	Prédicteur à horizon h	16
1.13.3	Pourquoi l'espérance conditionnelle ?	16
1.13.4	Erreur de prévision	17
1.14	Exemple intégrateur	18
1.15	Méthode générale d'analyse d'une nouvelle série	19
1.16	Erreurs conceptuelles fréquentes	20
1.16.1	Erreur 1 — Confondre numéro de ligne et temps	20
1.16.2	Erreur 2 — Mélanger fréquence et saisonnalité	20
1.16.3	Erreur 3 — Confondre saisonnalité et cycle	21
1.16.4	Erreur 4 — Déclarer un résidu « bruit blanc » par définition	21
1.16.5	Erreur 5 — Mélanger hasard et absence de structure	21
1.16.6	Erreur 6 — Mélanger futur et passé	21
1.16.7	Erreur 7 — Choisir ARIMA avant d'examiner les données	21
1.17	Première application Python	21
1.18	Synthèse du chapitre	22
1.19	Transition vers les chapitres suivants	22
1.20	Références utilisées pour ce chapitre	23
1.21	Exercices et problèmes	23
1.21.1	Niveau A — Compréhension	23
1.21.2	Niveau B — Calcul	24
1.21.3	Niveau C — Démonstration	25
1.21.4	Niveau D — Python	27
1.21.5	Niveau E — Études de cas	28
1.21.6	Questions orales possibles	29

Repères pour la suite

30

CHAPITRE 1

Introduction mathématique aux séries chronologiques

Niveau : Master Data Science / Intelligence Artificielle

Orientation : principes mathématiques, statistiques et applications

Python

Statut : version complète v1

Fil conducteur du chapitre

Une série chronologique n'est pas un tableau de nombres auquel on aurait ajouté une colonne de dates. L'ordre des observations constitue lui-même une partie de l'information statistique. Deux jeux de données contenant exactement les mêmes valeurs peuvent conduire à des conclusions opposées si ces valeurs sont arrangées différemment dans le temps.

L'objectif de ce chapitre est d'installer le langage utilisé dans tout le cours : index temporel, fréquence, retard, horizon, processus stochastique, trajectoire, tendance, saisonnalité, cycle, composante aléatoire, moyenne temporelle, autocovariance, autocorrélation, opérateur retard et prévision conditionnelle.

Le chapitre ne cherche pas encore à ajuster un modèle ARIMA. Il prépare la théorie qui rendra possible une telle modélisation.

Question directrice

Qu'est-ce qui distingue mathématiquement et statistiquement une suite d'observations temporelles d'un échantillon classique de données indépendantes ?

La réponse se résume à trois idées :

- 1. l'ordre temporel est informatif ;*
- 2. les observations peuvent être dépendantes ;*
- 3. une seule trajectoire observée doit permettre d'inférer un mécanisme aléatoire sous-jacent.*

1.1 Objectifs d'apprentissage

À la fin de ce chapitre, l'étudiant doit être capable de :

- définir rigoureusement une série temporelle et son index temporel ;
- distinguer temps discret et temps continu ;
- identifier fréquence d'observation, période saisonnière, retard et horizon ;

- distinguer série observée et processus stochastique sous-jacent ;
- interpréter une série comme une réalisation d'un processus aléatoire ;
- décomposer une série en composantes déterministes et aléatoires ;
- distinguer tendance, saisonnalité, cycle et résidu ;
- choisir entre un schéma additif et multiplicatif ;
- manipuler les premières quantités probabilistes temporelles ;
- expliquer pourquoi les données temporelles ne sont généralement pas i.i.d. ;
- utiliser les opérateurs retard et différence ;
- formuler une prévision comme une espérance conditionnelle ;
- implémenter les concepts précédents en Python.

1.2 Qu'est-ce qu'une série chronologique ?

1.2.1 Définition

Définition 2.1 - Série temporelle observée

Une **série chronologique** ou **série temporelle** est une famille ordonnée d'observations

$$(y_t)_{t \in \mathcal{T}},$$

où t représente le temps et $\mathcal{T}$ l'ensemble des instants observés.

Dans un cadre discret fini, on écrit souvent

$$y_1, y_2, \dots, y_T.$$

L'indice t n'est pas un simple numéro de ligne. Il représente une position dans le temps : seconde, minute, heure, jour, mois, trimestre, année, etc.

Exemple 2.1

Une base mensuelle de ventes sur cinq ans contient

$$T = 5 \times 12 = 60$$

observations. Si la première observation correspond à janvier 2021, alors y_{13} correspond à janvier 2022.

1.2.2 Pourquoi l'ordre compte-t-il ?

Considérons les valeurs

$$10, 14, 15, 20, 22, 25.$$

Dans cet ordre, elles suggèrent une progression. Considérons maintenant une permutation :

$$20, 10, 25, 15, 22, 14.$$

Les deux suites ont :

- la même moyenne ;
- la même variance ;
- le même minimum ;
- le même maximum ;
- le même histogramme.

Mais leur structure temporelle est différente.

Proposition 2.1 - Invariance des statistiques symétriques par permutation

Soient $y_1, \dots, y_T$ et une permutation π de $\{1, \dots, T\}$. Alors

$$\frac{1}{T} \sum_{t=1}^T y_t = \frac{1}{T} \sum_{t=1}^T y_{\pi(t)}.$$

Il en est de même pour la variance empirique, les quantiles et toute statistique qui dépend uniquement du multienemble des valeurs et non de leur ordre.

Preuve

Une permutation réordonne les termes d'une somme sans en modifier les valeurs. Ainsi

$$\sum_{t=1}^T y_{\pi(t)} = \sum_{t=1}^T y_t.$$

Pour la variance empirique,

$$\sum_{t=1}^T (y_{\pi(t)} - \bar{y})^2 = \sum_{t=1}^T (y_t - \bar{y})^2,$$

car les mêmes termes sont additionnés dans un ordre différent. ■

Conséquence

Des statistiques descriptives classiques peuvent être identiques alors que la dynamique temporelle est totalement différente. Pour analyser une série, on doit donc employer des outils sensibles à l'ordre : retards, autocovariances, autocorrélations, modèles dynamiques, etc.

1.3 Temps discret, temps continu et irrégularité

1.3.1 Temps discret

Un processus en temps discret est indexé par exemple par

$$t \in \mathbb{Z} \quad \text{ou} \quad t \in \{1, \dots, T\}.$$

Les séries mensuelles, trimestrielles ou journalières sont généralement étudiées

dans ce cadre.

1.3.2 Temps continu

Un processus en temps continu est défini pour

$$t \in \mathbb{R}_+.$$

On note alors souvent

$$Y(t), \quad t \geq 0.$$

Exemples : température physique instantanée, mouvement d'un actif dans certains modèles financiers continus, signaux biologiques.

1.3.3 Échantillonnage d'un phénomène continu

Un phénomène peut évoluer continuellement alors que les données ne sont enregistrées qu'à certains instants. Une série discrète peut ainsi être une version échantillonnée d'un système continu.

1.3.4 Séries irrégulièrement espacées

Il ne faut pas confondre « série ordonnée » et « série régulièrement échantillonnée ». Des transactions financières, des événements médicaux ou des pannes peuvent arriver à des instants irréguliers.

Lorsque l'espacement varie, certaines méthodes standard nécessitent une adaptation ou un rééchantillonnage.

1.4 Fréquence, période, retard et horizon

1.4.1 Fréquence d'observation

La fréquence décrit l'espacement temporel entre deux observations successives.

Série	Fréquence typique
PIB	trimestrielle
inflation	mensuelle
ventes web	quotidienne / horaire
électricité	horaire / 30 min / 15 min
prix financier	seconde / minute / jour
météo	minute / heure / jour

Attention

La **fréquence d'observation** n'est pas la **période saisonnière**.

Une série quotidienne peut avoir une saisonnalité hebdomadaire de période $s = 7$, et éventuellement une saisonnalité annuelle proche de 365.

Une série mensuelle a une fréquence mensuelle et peut présenter une saisonnalité annuelle de période

$$s = 12.$$

1.4.2 Retard — lag

Définition 4.1

Pour $k \geq 1$, la quantité

$$y_{t-k}$$

est la valeur de la série retardée de k périodes.

- $k = 1$: retard 1 ;
- $k = 12$ sur une série mensuelle : valeur un an auparavant ;
- $k = 7$ sur une série quotidienne : valeur une semaine auparavant.

Les couples

$$(y_t, y_{t-k})$$

seront essentiels pour étudier la dépendance temporelle.

1.4.3 Horizon de prévision

À la date t , prévoir Y_{t+h} correspond à une prévision à horizon h .

- $h = 1$: un pas ;
- $h = 6$: six pas ;
- $h = 12$ sur une série mensuelle : un an.

Un modèle peut être excellent à $h = 1$ et beaucoup moins performant à $h = 12$. L'horizon est donc une partie du problème, pas seulement un paramètre technique.

1.5 Série observée et processus stochastique

La statistique des séries temporelles repose sur une distinction fondamentale entre les données effectivement observées et le mécanisme probabiliste censé les avoir générées.

1.5.1 Processus stochastique

Définition 5.1

Un **processus stochastique** est une famille de variables aléatoires

$$\{Y_t : t \in \mathcal{T}\}.$$

À chaque date t , Y_t est une variable aléatoire.

Une observation réalisée est notée en minuscules :

$$y_t.$$

La suite observée

$$y_1, \dots, y_T$$

est appelée une **réalisation** ou **trajectoire** du processus.

1.5.2 Interprétation probabiliste

Pour un instant fixé t_0 , Y_{t_0} est une variable aléatoire dotée d'une distribution.

Pour deux instants t_1, t_2 , le couple

$$(Y_{t_1}, Y_{t_2})$$

possède une distribution jointe. Plus généralement,

$$(Y_{t_1}, \dots, Y_{t_n})$$

possède une distribution jointe finie-dimensionnelle.

En théorie, la collection de toutes ces lois caractérise complètement le processus, sous les conditions usuelles de compatibilité. En pratique, on s'appuie souvent sur les moments de premier et second ordre.

1.5.3 Une seule trajectoire : difficulté centrale

En économie ou en finance, on ne dispose généralement pas de centaines de mondes parallèles donnant chacun un PIB marocain entre 2000 et 2026. On observe une seule trajectoire historique.

Cela pose une question fondamentale :

Comment estimer les propriétés d'un processus à partir d'une seule réalisation ?

Les notions de stationnarité et d'ergodicité, étudiées plus loin, fournissent une réponse partielle en permettant de relier moyennes temporelles et quantités probabilistes.

1.6 Décomposition déterministe et aléatoire

Une représentation élémentaire consiste à écrire

$$Y_t = D_t + N_t,$$

où :

- D_t est la partie déterministe ;
- N_t la partie aléatoire.

1.6.1 Composante déterministe

Une fonction déterministe de t ne comporte aucun aléa une fois les paramètres fixés.

Exemples :

$$D_t = a + bt,$$

$$D_t = a + bt + ct^2,$$

$$D_t = A \sin(\omega t + \varphi).$$

1.6.2 Composante aléatoire

La partie N_t représente ce qui ne peut être décrit exactement par la partie déterministe choisie.

Important : aléatoire ne signifie pas sans structure.

Les processus suivants sont aléatoires mais structurés :

- AR(1) ;
- ARMA ;
- marche aléatoire ;
- GARCH.

Un résidu qui conserve une dépendance temporelle n'est donc pas assimilable automatiquement à un bruit blanc.

1.7 Composantes classiques d'une série temporelle

Une décomposition descriptive traditionnelle écrit

$$Y_t = T_t + C_t + S_t + \varepsilon_t,$$

où T_t désigne la tendance, C_t le cycle, S_t la saisonnalité et ε_t la composante résiduelle.

Cette écriture est un **modèle de représentation**, pas une identité universelle.

1.7.1 Tendance

La tendance décrit l'évolution de long terme du niveau moyen.

Tendance linéaire

$$T_t = a + bt.$$

- $b > 0$: croissance ;
- $b < 0$: décroissance ;
- $b = 0$: niveau constant.

Tendance polynomiale

$$T_t = a + bt + ct^2.$$

Tendance exponentielle

$$T_t = Ae^{gt}.$$

Dans ce dernier cas,

$$\log T_t = \log A + gt,$$

ce qui transforme une tendance exponentielle positive en tendance linéaire dans l'échelle logarithmique.

1.7.2 Saisonnalité

Une composante saisonnière possède une périodicité relativement stable.

Définition 7.1

Une saisonnalité de période s vérifie idéalement

$$S_{t+s} = S_t.$$

Exemple sinusoïdal :

$$S_t = A \sin \left(\frac{2\pi t}{s} + \varphi \right).$$

Pour des données mensuelles avec répétition annuelle :

$$s = 12.$$

Vérification de la périodicité sinusoïdale

$$S_{t+s} = A \sin \left(\frac{2\pi(t+s)}{s} + \varphi \right) = A \sin \left(\frac{2\pi t}{s} + 2\pi + \varphi \right) = S_t.$$

1.7.3 Cycle

Le cycle représente des fluctuations de moyen ou long terme qui ne sont généralement pas strictement périodiques.

La distinction est conceptuellement importante :

saisonnalité $\Rightarrow$ période stable ou quasi stable,

cycle $\Rightarrow$ durée potentiellement variable.

Les cycles économiques constituent un exemple classique.

1.7.4 Résidu

Dans une décomposition additive,

$$\varepsilon_t = Y_t - T_t - C_t - S_t.$$

Un résidu bien défini n'est pas nécessairement un bruit blanc. Il peut encore présenter :

- autocorrélation ;
- variance conditionnelle variable ;
- valeurs extrêmes ;
- ruptures ;
- non-normalité.

Le diagnostic des résidus sera donc une étape obligatoire de la modélisation.

1.8 Décomposition additive et multiplicative

1.8.1 Modèle additif

$$Y_t = T_t + C_t + S_t + \varepsilon_t.$$

Il est naturel lorsque l'amplitude des fluctuations saisonnières reste approximativement constante lorsque le niveau change.

1.8.2 Modèle multiplicatif

Une représentation courante est

$$Y_t = T_t C_t S_t \varepsilon_t,$$

ou, selon le contexte, une version simplifiée

$$Y_t = T_t S_t \varepsilon_t.$$

Elle est pertinente lorsque l'amplitude des fluctuations augmente avec le niveau.

Exemple

Une entreprise peut avoir un effet saisonnier de +20 % en décembre. Une hausse de 20 % ne représente pas la même quantité absolue lorsque le niveau moyen des ventes vaut 100 ou 10 000.

1.8.3 Transformation logarithmique

Supposons toutes les composantes strictement positives :

$$Y_t = T_t S_t \varepsilon_t.$$

Alors

$$\log Y_t = \log T_t + \log S_t + \log \varepsilon_t.$$

Proposition 8.1

Le logarithme transforme un modèle multiplicatif strictement positif en modèle additif dans l'échelle logarithmique.

Preuve

Elle découle de l'identité

$$\log(abc) = \log a + \log b + \log c$$

pour $a, b, c > 0$. ■

Attention - domaine du logarithme

La transformation $\log Y_t$ exige $Y_t > 0$. En présence de zéros ou de valeurs négatives, il faut utiliser une autre transformation ou justifier un décalage, ce qui modifie l'interprétation.

1.9 Pourquoi les observations temporelles ne sont-elles pas i.i.d. ?

Dans un échantillon classique, on rencontre souvent l'hypothèse

$$X_1, \dots, X_n \stackrel{iid}{\sim} F.$$

Cela implique :

1. même distribution ;
2. indépendance.

Dans une série temporelle, la dépendance au passé est souvent précisément le phénomène que l'on cherche à étudier.

Exemple 9.1 - relation autorégressive

$$Y_t = \phi Y_{t-1} + \varepsilon_t.$$

Même si ε_t est indépendant du passé, Y_t dépend de Y_{t-1} .

1.9.1 Conséquence sur l'information statistique

Si les observations sont fortement corrélées, T observations n'apportent pas nécessairement autant d'information que T observations indépendantes.

Pour illustrer l'idée, supposons que

$$Y_1 = Y_2 = \dots = Y_T = Z.$$

On possède formellement T valeurs mais elles sont toutes identiques. Pour estimer la moyenne de Z , on n'a pas réellement obtenu T réalisations indépendantes.

À l'inverse, avec T variables i.i.d., chaque observation apporte de l'information nouvelle.

Cette question conduit à la notion de **taille d'échantillon effective**, qui sera évoquée plus tard.

1.10 Premières quantités probabilistes temporelles

Les définitions suivantes sont générales et seront approfondies dans les chapitres sur les processus stochastiques et la stationnarité.

1.10.1 Fonction moyenne

$$\mu_t = \mathbb{E}[Y_t].$$

Dans le cas général, la moyenne peut dépendre de t .

1.10.2 Variance

$$\sigma_t^2 = \text{Var}(Y_t) = \mathbb{E}[(Y_t - \mu_t)^2].$$

Elle peut également dépendre du temps.

1.10.3 Autocovariance

Pour deux dates t et s ,

$$\gamma(t, s) = \text{Cov}(Y_t, Y_s) = \mathbb{E}[(Y_t - \mu_t)(Y_s - \mu_s)].$$

Cette quantité mesure la liaison linéaire entre les valeurs du processus à deux instants.

1.10.4 Autocorrélation

Si les variances sont strictement positives,

$$\rho(t, s) = \frac{\gamma(t, s)}{\sqrt{\text{Var}(Y_t) \text{Var}(Y_s)}}.$$

Elle est sans unité.

Proposition 10.1

$$|\rho(t, s)| \leq 1.$$

Preuve par Cauchy-Schwarz

Posons

$$X = Y_t - \mu_t, \quad Z = Y_s - \mu_s.$$

L'inégalité de Cauchy-Schwarz donne

$$|\mathbb{E}[XZ]|^2 \leq \mathbb{E}[X^2] \mathbb{E}[Z^2].$$

Donc

$$|\gamma(t, s)| \leq \sqrt{\text{Var}(Y_t) \text{Var}(Y_s)}.$$

En divisant par le dénominateur positif, on obtient

$$|\rho(t, s)| \leq 1.$$

■

1.11 Exemples mathématiques fondamentaux

1.11.1 Tendance déterministe + bruit centré

Considérons

$$Y_t = a + bt + \varepsilon_t,$$

avec

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2.$$

Alors

$$\mathbb{E}[Y_t] = a + bt,$$

et, puisque $a + bt$ est déterministe,

$$\text{Var}(Y_t) = \text{Var}(\varepsilon_t) = \sigma^2.$$

La variance est constante mais la moyenne dépend du temps lorsque $b \neq 0$.

1.11.2 Saisonnalité déterministe + bruit

$$Y_t = A \sin\left(\frac{2\pi t}{12}\right) + \varepsilon_t,$$

avec $\mathbb{E}[\varepsilon_t] = 0$. Alors

$$\mathbb{E}[Y_t] = A \sin\left(\frac{2\pi t}{12}\right).$$

La moyenne est périodique, donc non constante.

1.11.3 Variance croissante

Soit

$$Y_t = t\varepsilon_t,$$

avec

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = 1.$$

Alors

$$\mathbb{E}[Y_t] = t\mathbb{E}[\varepsilon_t] = 0,$$

mais

$$\text{Var}(Y_t) = t^2 \text{Var}(\varepsilon_t) = t^2.$$

La moyenne est constante, mais la variance ne l'est pas.

1.11.4 Premier exemple de dépendance temporelle

$$Y_t = 0.8Y_{t-1} + \varepsilon_t.$$

Le présent dépend directement du passé. Si deux trajectoires possèdent des valeurs différentes à $t - 1$, leurs distributions conditionnelles à t sont décalées de

$$0.8 (Y_{t-1}^{(1)} - Y_{t-1}^{(2)}).$$

Cette dépendance est la base des modèles autorégressifs.

1.11.5 Marche aléatoire — aperçu

Considérons

$$Y_t = Y_{t-1} + \varepsilon_t,$$

où les ε_t sont centrés, indépendants et de variance σ^2 .

Par substitutions successives,

$$Y_t = Y_0 + \sum_{j=1}^t \varepsilon_j.$$

Si Y_0 est constant,

$$\text{Var}(Y_t) = \sum_{j=1}^t \text{Var}(\varepsilon_j) = t\sigma^2.$$

La variance augmente avec le temps. Ce processus est l'exemple canonique qui annonce les problèmes de non-stationnarité et les modèles ARIMA.

1.12 Opérateur retard

1.12.1 Définition

L'opérateur retard L agit sur une série par

$$LY_t = Y_{t-1}.$$

Plus généralement,

$$L^k Y_t = Y_{t-k}.$$

Exemple

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

s'écrit

$$Y_t - \phi LY_t = \varepsilon_t,$$

soit

$$(1 - \phi L)Y_t = \varepsilon_t.$$

Cette notation devient indispensable pour ARMA, ARIMA et SARIMA.

1.12.2 Opérateur différence

La différence première est

$$\Delta Y_t = Y_t - Y_{t-1}.$$

Avec L ,

$$\Delta Y_t = (1 - L)Y_t.$$

Proposition 12.1 - différence d'une tendance linéaire

Si

$$T_t = a + bt,$$

alors

$$\Delta T_t = b.$$

Preuve

$$\Delta T_t = T_t - T_{t-1} = (a + bt) - [a + b(t-1)] = b.$$



Cette propriété explique pourquoi la différenciation élimine une tendance linéaire déterministe au premier ordre.

1.12.3 Différence seconde d'un polynôme quadratique

Si

$$T_t = a + bt + ct^2,$$

la première différence est linéaire en t , et la seconde différence est constante.

En effet,

$$\Delta T_t = b + c(2t - 1),$$

puis

$$\Delta^2 T_t = 2c.$$

Cette propriété générale des différences finies annonce le rôle du paramètre d dans ARIMA.

1.13 La prévision comme problème conditionnel

1.13.1 Ensemble d'information

Notons

$$\mathcal{F}_t$$

l'information disponible jusqu'à la date t . Selon le modèle, elle peut inclure

$$Y_t, Y_{t-1}, \dots$$

ainsi que des variables exogènes.

1.13.2 Prédicteur à horizon h

Une prévision basée sur l'information passée est notée

$$\hat{Y}_{t+h|t}.$$

Sous perte quadratique, le prédicteur théorique optimal est

$$\hat{Y}_{t+h|t} = \mathbb{E}[Y_{t+h} \mid \mathcal{F}_t].$$

1.13.3 Pourquoi l'espérance conditionnelle ?

Théorème 13.1 - optimalité sous erreur quadratique

Soit $Y \in L^2$ et $\mathcal{G}$ une information disponible. Parmi toutes les variables aléatoires g mesurables par rapport à $\mathcal{G}$, la quantité

$$m = \mathbb{E}[Y \mid \mathcal{G}]$$

minimise

$$\mathbb{E}[(Y - g)^2].$$

Preuve

Écrivons

$$Y - g = (Y - m) + (m - g).$$

En élevant au carré,

$$(Y - g)^2 = (Y - m)^2 + (m - g)^2 + 2(Y - m)(m - g).$$

En prenant l'espérance :

$$\mathbb{E}[(Y - g)^2] = \mathbb{E}[(Y - m)^2] + \mathbb{E}[(m - g)^2] + 2\mathbb{E}[(Y - m)(m - g)].$$

Comme $m - g$ est $\mathcal{G}$ -mesurable,

$$\mathbb{E}[(Y - m)(m - g)] = \mathbb{E}[(m - g) \mathbb{E}[Y - m \mid \mathcal{G}]].$$

Or

$$\mathbb{E}[Y - m \mid \mathcal{G}] = 0.$$

Donc

$$\mathbb{E}[(Y - g)^2] = \mathbb{E}[(Y - m)^2] + \mathbb{E}[(m - g)^2] \geq \mathbb{E}[(Y - m)^2].$$

Le minimum est obtenu pour $g = m$. ■

Interprétation

Prévoir n'est donc pas seulement extrapoler une tendance. Il s'agit de calculer la meilleure approximation d'une variable future à partir de l'information actuellement disponible, au sens d'une fonction de perte définie.

1.13.4 Erreur de prévision

L'erreur à horizon h est

$$e_{t+h|t} = Y_{t+h} - \hat{Y}_{t+h|t}.$$

Pour le prédicteur conditionnel moyen,

$$\mathbb{E}[e_{t+h|t} \mid \mathcal{F}_t] = 0.$$

Preuve

$$\mathbb{E}[e_{t+h|t} \mid \mathcal{F}_t] = \mathbb{E}[Y_{t+h} \mid \mathcal{F}_t] - \hat{Y}_{t+h|t} = 0.$$

Cette propriété sera utilisée dans toute la théorie de la prévision.

1.14 Exemple intégrateur

Considérons

$$Y_t = 30 + 0.18t + 5 \sin\left(\frac{2\pi t}{12}\right) + 2.5 \sin\left(\frac{2\pi t}{48}\right) + \varepsilon_t,$$

où

$$\varepsilon_t \sim \mathcal{N}(0, 1.2^2)$$

et les innovations sont indépendantes.

On identifie :

Tendance

$$T_t = 30 + 0.18t.$$

Saisonnalité

$$S_t = 5 \sin\left(\frac{2\pi t}{12}\right),$$

de période 12.

Cycle synthétique

$$C_t = 2.5 \sin\left(\frac{2\pi t}{48}\right).$$

Bruit

$$\varepsilon_t.$$

Fonction moyenne

Puisque $\mathbb{E}[\varepsilon_t] = 0$,

$$\mathbb{E}[Y_t] = 30 + 0.18t + 5 \sin\left(\frac{2\pi t}{12}\right) + 2.5 \sin\left(\frac{2\pi t}{48}\right).$$

La moyenne dépend du temps.

Variance

Toutes les composantes autres que ε_t sont déterministes. Donc

$$\text{Var}(Y_t) = 1.2^2 = 1.44.$$

Questions conceptuelles

1. Le modèle est-il additif? **Oui**.
2. La série est-elle i.i.d.? **Non**, car sa distribution marginale dépend de t via sa moyenne.
3. Le résidu est-il ici un bruit blanc? **Oui dans ce modèle simulé**, car on l'a explicitement supposé indépendant, centré et homoscedastique; sur des données réelles, cela devrait être diagnostiqué.
4. La saisonnalité est-elle annuelle si les données sont mensuelles? **Oui**, car $s = 12$.
5. Une simple moyenne globale décrit-elle correctement le niveau attendu? **Non**, car l'espérance varie avec t .

1.15 Méthode générale d'analyse d'une nouvelle série

Avant d'ajuster un modèle, suivre une procédure structurée.

Étape 1 — Définir la variable

- signification;
- unité;
- mécanisme de mesure;
- éventuelles transformations déjà appliquées.

Étape 2 — Définir l'index temporel

- date/heure;
- fuseau horaire si pertinent;
- fréquence;
- régularité de l'échantillonnage.

Étape 3 — Contrôler la chronologie

- tri;
- doublons;
- dates manquantes;
- observations manquantes.

Étape 4 — Tracer la série brute

Une modélisation temporelle doit presque toujours commencer par le graphique de y_t contre t .

Étape 5 — Examiner la tendance

- croissance ;
- décroissance ;
- changement de pente ;
- courbure.

Étape 6 — Examiner la saisonnalité

- période plausible ;
- amplitude ;
- stabilité dans le temps.

Étape 7 — Examiner la variance

- constante ;
- croissante ;
- dépendante du niveau ;
- groupes de forte/faible volatilité.

Étape 8 — Rechercher ruptures et anomalies

Une rupture structurelle peut rendre trompeur un modèle estimé sur toute la période.

Étape 9 — Examiner la dépendance

- lag plots ;
- ACF ;
- PACF plus tard.

Étape 10 — Formuler un premier modèle

Seulement après l'exploration, choisir une famille : décomposition, régression, ARMA/ARIMA, GARCH, VAR, espace d'état, etc.

1.16 Erreurs conceptuelles fréquentes**1.16.1 Erreur 1 — Confondre numéro de ligne et temps**

Le simple entier 1, 2, 3, ... ne contient pas automatiquement le calendrier réel.

1.16.2 Erreur 2 — Mélanger fréquence et saisonnalité

Mensuel ne signifie pas « saison de période 1 ». Pour une répétition annuelle sur données mensuelles, $s = 12$.

1.16.3 Erreur 3 — Confondre saisonnalité et cycle

La saisonnalité est liée à une périodicité relativement stable. Le cycle peut changer de durée.

1.16.4 Erreur 4 — Déclarer un résidu « bruit blanc » par définition

C'est une hypothèse à vérifier par diagnostic.

1.16.5 Erreur 5 — Mélanger hasard et absence de structure

Un processus aléatoire peut être hautement prévisible conditionnellement à son passé.

1.16.6 Erreur 6 — Mélanger futur et passé

Utiliser de l'information future pour construire des variables explicatives ou valider un modèle crée une **fuite d'information**.

1.16.7 Erreur 7 — Choisir ARIMA avant d'examiner les données

Une commande logicielle n'est pas une méthodologie statistique. Le modèle doit être justifié par les propriétés observées et les hypothèses du processus.

1.17 Première application Python

Le TP associé à ce chapitre reprend les concepts suivants :

1. création d'un index temporel ;
2. comparaison d'une série et d'une permutation ;
3. simulation tendance + saisonnalité + bruit ;
4. simulation d'une série multiplicative ;
5. transformation logarithmique ;
6. construction de retards ;
7. calcul empirique de covariance/corrélation à différents lags ;
8. simulation d'un bruit blanc et d'un AR(1) ;
9. comparaison de leurs dépendances ;
10. première prévision conditionnelle pour un AR(1) simulé.

Exemple minimal

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

rng = np.random.default_rng(123)
n = 120
t = np.arange(n)
```

```

y = (
    30
    + 0.18 * t
    + 5 * np.sin(2 * np.pi * t / 12)
    + 2.5 * np.sin(2 * np.pi * t / 48)
    + rng.normal(0, 1.2, n)
)

index = pd.date_range("2016-01-01", periods=n, freq="MS")
series = pd.Series(y, index=index, name="Y")

series.plot(figsize=(12, 4), title="Série synthétique")
plt.show()

```

1.18 Synthèse du chapitre

Les idées fondamentales à retenir sont :

1. une série temporelle est une suite **ordonnée** ;
2. l'ordre contient de l'information que les statistiques globales peuvent perdre ;
3. la série observée est interprétée comme une réalisation d'un processus stochastique ;
4. un processus est une famille de variables aléatoires $\{Y_t\}$;
5. une première représentation est $Y_t = D_t + N_t$;
6. une décomposition descriptive classique est $Y_t = T_t + C_t + S_t + \varepsilon_t$;
7. le schéma multiplicatif est utile lorsque l'amplitude varie avec le niveau ;
8. le logarithme transforme un produit positif en somme ;
9. les objets $\mathbb{E}[Y_t]$, $\text{Var}(Y_t)$, $\gamma(t, s)$ et $\rho(t, s)$ décrivent la structure probabiliste de second ordre ;
10. les observations temporelles ne sont généralement pas i.i.d. ;
11. l'opérateur retard L permet une écriture compacte des modèles dynamiques ;
12. la différence première s'écrit $\Delta = (1 - L)$;
13. sous perte quadratique, la prévision optimale est une espérance conditionnelle ;
14. avant toute modélisation, la série doit être explorée dans son ordre temporel.

1.19 Transition vers les chapitres suivants

Le chapitre 1 a défini l'objet temporel et les premières quantités probabilistes. La suite du cours procédera en deux directions :

- **description de la structure déterministe** : tendance, saisonnalité, décomposition, lissage ;
- **description de la structure probabiliste** : processus stochastiques, stationnarité, bruit blanc, autocovariance, AR, MA, ARMA et ARIMA.

La question centrale deviendra alors :

Quelles hypothèses permettent d'apprendre les propriétés d'un processus à partir d'une seule trajectoire observée ?

1.20 Références utilisées pour ce chapitre

- R. H. Shumway & D. S. Stoffer, *Time Series Analysis and Its Applications* : nature des données temporelles, dépendance, modélisation statistique et rôle de la visualisation.
- M. El Merouani, *Chapitre 1 — Processus Stochastiques* : série comme réalisation d'un processus, composantes déterministe/aléatoire, tendance, cycle, saisonnalité, résidu, moments.
- Contenu officiel du module *Time Series* : introduction, caractéristiques des séries, tendance, saisonnalité, cycles, visualisation, forecasting et applications.
- G. E. P. Box, G. M. Jenkins et collaborateurs : notation par opérateurs et cadre Box-Jenkins utilisé dans les chapitres ultérieurs.

1.21 Exercices et problèmes

Les exercices sont classés par niveau. Les solutions détaillées sont réservées au dossier `instructor/solutions`.

1.21.1 Niveau A — Compréhension

Exercice A1 — Index et fréquence

Une série contient 72 observations mensuelles consécutives.

1. Combien d'années couvre-t-elle ?
2. Quelle valeur de s correspond à une saisonnalité annuelle ?
3. Que représente le retard 12 ?
4. Que signifie une prévision à horizon 6 ?

Exercice A2 — Fréquence ou saisonnalité ?

Pour chacune des situations suivantes, distinguer fréquence d'observation et période saisonnière plausible :

1. consommation électrique enregistrée toutes les heures avec répétition journalière ;
2. ventes quotidiennes avec effet du week-end ;
3. trafic web mensuel avec effet annuel ;
4. données trimestrielles avec effet annuel.

Exercice A3 — Série observée ou processus ?

Expliquer la différence entre les notations y_t et $y_{_t}$.

Exercice A4 — Cycle ou saisonnalité ?

Classer et justifier :

1. hausse répétée des ventes chaque décembre ;
2. expansion puis récession économique de durée variable ;
3. trafic plus faible chaque dimanche ;
4. oscillation imposée de période exactement 24.

Exercice A5 — Résidu

Pourquoi ne peut-on pas déclarer automatiquement qu'un résidu est un bruit blanc ?
Donner trois structures qui peuvent rester dans les résidus.

1.21.2 Niveau B — Calcul**Exercice B1 — Décomposition additive**

À la date t , on observe :

$$T_t = 120, \quad C_t = -5, \quad S_t = 15, \quad \varepsilon_t = 3.$$

Calculer γ_t dans un modèle additif.

Exercice B2 — Décomposition multiplicative

On suppose

$$T_t = 200, \quad S_t = 1.10, \quad \varepsilon_t = 0.95.$$

En négligeant le cycle, calculer γ_t .

Exercice B3 — Fonction moyenne

Soit

$$Y_t = 5 + 0.4t + \varepsilon_t, \quad E(\varepsilon_t) = 0.$$

1. Déterminer $E(Y_t)$.
2. Calculer $E(Y_{10})$ et $E(Y_{50})$.
3. La moyenne théorique est-elle constante ?

Exercice B4 — Variance non constante

Soit

$$Y_t = \sqrt{t} \varepsilon_t, \quad \text{Var}(\varepsilon_t) = 4.$$

Déterminer $\text{Var}(Y_t)$.

Exercice B5 — Périodicité

Soit

$$S_t = 3 \cos\left(\frac{2\pi t}{4}\right).$$

1. Calculer $s_0, \dots, s_7$.
2. Identifier la période.
3. Vérifier numériquement $s_{t+4}=s_t$.

Exercice B6 — Opérateur retard

Écrire avec l'opérateur L :

1. $Y_t = 0.7Y_{t-1} + \text{eps}_t$;
2. $Y_t = 0.5Y_{t-1} - 0.2Y_{t-2} + \text{eps}_t$;
3. $\Delta Y_t = Y_t - Y_{t-1}$.

Exercice B7 — Tendence et différence

Soit

$$Y_t = 2 + 3t.$$

Calculer ΔY_t .

Exercice B8 — Quadratique et seconde différence

Soit

$$T_t = 2 + 3t + 0.5t^2.$$

1. Calculer ΔT_t .
2. Calculer $\Delta^2 T_t$.
3. Interpréter.

1.21.3 Niveau C — Démonstration**Exercice C1 — Moyenne et permutation**

Montrer que la moyenne empirique est invariante par permutation des observations.

Exercice C2 — Variance et permutation

Montrer que la variance empirique est elle aussi invariante par permutation.

Exercice C3 — Périodicité sinusoïdale

Soit

$$S_t = A \sin \left(\frac{2\pi t}{s} + \varphi \right).$$

Montrer que $S_{t+s} = S_t$.

Exercice C4 — Borne de corrélation

À partir de Cauchy-Schwarz, démontrer que

$$|\rho(t, s)| \leq 1.$$

Exercice C5 — Marche aléatoire

Soit

$$Y_t = Y_{t-1} + \varepsilon_t,$$

où les innovations sont indépendantes, centrées et de variance σ^2 , avec Y_0 constant.

1. Montrer que

$$Y_t = Y_0 + \sum_{j=1}^t \varepsilon_j.$$

2. En déduire

$$\text{Var}(Y_t) = t\sigma^2.$$

3. Pourquoi cela suggère-t-il une non-stationnarité ?

Exercice C6 — Prévision conditionnelle

Soit $m = E(Y|G)$.

Démontrer que, pour toute variable g mesurable par rapport à G ,

$$E[(Y - g)^2] = E[(Y - m)^2] + E[(m - g)^2].$$

En déduire que m minimise l'erreur quadratique moyenne.

Exercice C7 — Erreur de prévision conditionnellement centrée

Si

$$\hat{Y}_{t+h|t} = E(Y_{t+h} | \mathcal{F}_t),$$

montrer que

$$E[e_{t+h}|t|\mathcal{F}_t] = 0.$$

1.21.4 Niveau D — Python

Exercice D1 — L'ordre contient de l'information

Créer le tableau

```
x = [10, 14, 15, 20, 22, 25]
```

puis une permutation aléatoire.

1. Comparer moyenne, variance et histogramme.
2. Tracer les deux séries dans leur ordre temporel.
3. Comparer leur corrélation au retard 1.
4. Commenter.

Exercice D2 — Série synthétique

Simuler $n=120$ observations de

$$Y_t = 30 + 0.18t + 5 \sin(2\pi t/12) + \varepsilon_t,$$

avec $\varepsilon_t \sim N(0, 1.2^2)$.

1. Construire un index mensuel pandas.
2. Tracer la série.
3. Tracer séparément tendance et saisonnalité.
4. Vérifier visuellement la période 12.

Exercice D3 — Additif vs multiplicatif

Construire deux séries ayant la même tendance croissante :

- une saisonnalité additive ;
- une saisonnalité multiplicative.

Comparer les amplitudes saisonnières au début et à la fin.

Exercice D4 — Effet du logarithme

Sur la série multiplicative positive de D3 :

1. tracer Y_t ;
2. tracer $\log(Y_t)$;
3. expliquer ce qui change dans l'amplitude saisonnière.

Exercice D5 — Bruit blanc et AR(1)

Simuler :

- un bruit blanc de taille 500;
- un AR(1) avec $\phi=0.85$.

Comparer :

1. graphiques temporels;
2. lag plots;
3. ACF;
4. corrélation empirique au retard 1.

Exercice D6 — Marche aléatoire

Simuler 1 000 trajectoires de marche aléatoire de longueur 200.

1. Estimer empiriquement $\text{Var}(Y_t)$ à différents instants t .
2. Vérifier graphiquement que la variance est approximativement linéaire en t .
3. Comparer avec la formule théorique.

Exercice D7 — Fuite d'information

Créer une série mensuelle et une moyenne mobile centrée utilisant une observation future.

1. Montrer pourquoi cette variable est inutilisable pour une prévision temps réel.
2. Construire une version utilisant uniquement le passé.

1.21.5 Niveau E — Études de cas**Exercice E1 — Ventes mensuelles**

Vous recevez 6 ans de ventes mensuelles d'un commerce.

Rédiger un protocole d'analyse avant toute estimation de modèle. Le protocole doit contenir au moins :

- contrôle de l'index;
- visualisation;
- recherche de tendance;
- recherche de saisonnalité;
- examen de l'amplitude;
- valeurs manquantes;
- anomalies;
- première hypothèse de décomposition.

Exercice E2 — Prix financier

Un prix d'action croît globalement tandis que l'amplitude des fluctuations augmente avec le niveau.

1. Un schéma additif ou multiplicatif paraît-il plus naturel ?
2. Pourquoi un logarithme peut-il être intéressant ?
3. Pourquoi ne faut-il pas conclure immédiatement que les prix sont stationnaires ?

Exercice E3 — Électricité horaire

On dispose de deux années de consommation électrique horaire.

1. Quelles périodicités chercher ?
2. Quels retards sont naturellement intéressants ?
3. Quels problèmes de calendrier peuvent apparaître ?
4. Proposer au moins cinq graphiques exploratoires.

Exercice E4 — Mini-projet

Choisir une série réelle ou publique et produire une note de 3 à 5 pages contenant :

1. définition de la variable et de l'index ;
2. graphique brut ;
3. fréquence et périodes plausibles ;
4. hypothèse additif/multiplicatif ;
5. moyenne/variance empiriques ;
6. deux graphiques de retards ;
7. première ACF ;
8. conclusion sur les difficultés de modélisation.

1.21.6 Questions orales possibles

1. Pourquoi un histogramme ne suffit-il pas à décrire une série temporelle ?
2. Quelle différence entre une trajectoire et un processus ?
3. Pourquoi une série de résidus n'est-elle pas forcément un bruit blanc ?
4. Quelle différence entre fréquence et période ?
5. Pourquoi l'espérance conditionnelle intervient-elle dans la prévision ?
6. À quoi sert l'opérateur retard ?
7. Pourquoi la marche aléatoire annonce-t-elle la non-stationnarité ?

Repères pour la suite

Le chapitre suivant sera consacré à l'ajustement de la tendance, à la saisonnalité, à la décomposition et au lissage. La même chaîne éditoriale LaTeX sera réutilisée pour l'ensemble du cours afin de produire à terme un manuel unique et cohérent.