

MASTER — SÉRIES CHRONOLOGIQUES

Chapitre 2

Tendance, saisonnalité, décomposition et lissage

Théorie statistique, preuves et applications Python

Version imprimable - LaTeX

Table des matières

2 Tendance, saisonnalité, décomposition et lissage	1
Fil conducteur du chapitre	1
2.1 Objectifs d'apprentissage	2
2.2 Modèle déterministe de tendance	2
2.2.1 Séparer structure moyenne et fluctuation	2
2.2.2 Tendance linéaire	3
2.2.3 Tendance polynomiale	3
2.3 Moindres carrés ordinaires : dérivation complète	3
2.3.1 Formulation matricielle	4
2.3.2 Cas de la tendance linéaire	5
2.4 Propriétés statistiques de l'estimateur MCO	6
2.4.1 Absence de biais	6
2.4.2 Matrice de covariance	6
2.4.3 Estimation de σ^2	7
2.4.4 Le problème spécifique des séries temporelles	7
2.5 Projection géométrique et résidus	7
2.6 Tendance exponentielle et transformation logarithmique	8
2.7 Représenter la saisonnalité par variables indicatrices	9
2.7.1 Modèle saisonnier additif	9
2.7.2 Piège des variables indicatrices	9
2.8 Régression harmonique	10
2.8.1 Forme amplitude-phase	10
2.9 Décomposition additive et multiplicative	11
2.9.1 Modèle additif	11
2.9.2 Modèle multiplicatif	11
2.10 Moyennes mobiles simples et centrées	11
2.10.1 Moyenne mobile de largeur impaire	11
2.10.2 Interprétation comme filtre linéaire	11
2.10.3 Conservation d'une tendance linéaire par un filtre symétrique	12
2.11 Effet de la moyenne mobile sur un bruit blanc	13
2.12 Moyenne mobile et élimination d'une saisonnalité	13
2.13 Moyennes mobiles pondérées et noyaux	14
2.14 Lissage exponentiel simple	15
2.14.1 Forme en moyenne pondérée du passé	15
2.15 Méthode de Holt : niveau et tendance locale	16
2.16 Holt-Winters et saisonnalité	16
2.17 LOWESS et régression locale	17
2.18 Splines de lissage	17
2.19 STL : décomposition saisonnière robuste	18
2.20 Biais-variance du lissage	19
2.21 Effets de bord et causalité	19
2.22 Exemple analytique intégrateur	20
2.22.1 Fonction moyenne	20

2.22.2 Amplitude de la composante harmonique	20
2.22.3 Variance conditionnelle à la structure déterministe	20
2.22.4 Modèle de régression associé	20
2.23 Méthode pratique de choix d'un lisseur	20
2.24 Application Python	21
2.25 Erreurs conceptuelles fréquentes	21
2.25.1 Erreur 1 — assimiler « lisse » à « vrai »	21
2.25.2 Erreur 2 — utiliser les tests MCO classiques malgré des résidus autocorrélés	22
2.25.3 Erreur 3 — sur-ajuster un polynôme	22
2.25.4 Erreur 4 — confondre composante saisonnière et moyenne mo- bile	22
2.25.5 Erreur 5 — ignorer l'identifiabilité des indicatrices	22
2.25.6 Erreur 6 — oublier la causalité	22
2.25.7 Erreur 7 — croire que les résidus d'un lissage sont un bruit blanc	22
2.26 Synthèse du chapitre	22
2.27 Transition vers le chapitre 3	23
2.28 Références utilisées pour ce chapitre	23
2.29 Exercices et problèmes	23
2.29.1 Niveau A — Compréhension	23
2.29.2 Niveau B — Calcul	24
2.29.3 Niveau C — Démonstration	25
2.29.4 Niveau D — Python	26
2.29.5 Niveau E — Études de cas	27

CHAPITRE 2

Tendance, saisonnalité, décomposition et lissage

Niveau : Master Data Science / Intelligence Artificielle

Orientation : théorie statistique, preuves mathématiques et applications Python

Statut : version complète v1

Fil conducteur du chapitre

Une série temporelle observée mélange souvent plusieurs mécanismes : une évolution de long terme, des répétitions calendaires, des fluctuations de moyen terme et une composante aléatoire. Avant de chercher un modèle ARMA ou ARIMA, il faut apprendre à séparer ces mécanismes, au moins approximativement.

Le présent chapitre étudie trois familles d'outils complémentaires :

1. **régression déterministe**, pour représenter une tendance ou une saisonnalité paramétrique ;
2. **décomposition**, pour distinguer tendance, saisonnalité et reste ;
3. **lissage**, pour estimer une structure lente sans imposer une forme globale trop rigide.

Cette progression suit l'esprit du chapitre 2 de Shumway et Stoffer : la tendance peut être étudiée par régression, puis des lisseurs globaux ou locaux permettent d'estimer une fonction temporelle plus souple. Le support officiel du module exige explicitement l'ajustement de la tendance et le lissage par moyennes mobiles.




Figure 2.1 – Exemple synthétique combinant tendance, saisonnalité et bruit.

Question directrice

Comment extraire une structure déterministe utile sans confondre lissage descriptif et modèle probabiliste de la série ?

La réponse demande de distinguer soigneusement :

- *la fonction moyenne ou la tendance théorique ;*
- *son estimateur obtenu à partir d'une trajectoire finie ;*
- *les résidus après ajustement ;*
- *la dépendance temporelle qui peut subsister dans ces résidus.*

2.1 Objectifs d'apprentissage

À la fin du chapitre, l'étudiant doit être capable de :

- formuler une tendance comme un modèle de régression temporelle ;
- dériver l'estimateur des moindres carrés ordinaires ;
- établir son absence de biais et sa matrice de covariance sous hypothèses classiques ;
- comprendre pourquoi l'autocorrélation des erreurs invalide certaines formules usuelles d'inférence ;
- ajuster une tendance linéaire, polynomiale ou exponentielle ;
- représenter une saisonnalité par indicatrices ou par fonctions harmoniques ;
- expliquer le problème d'identifiabilité des indicatrices saisonnières ;
- construire et interpréter des décompositions additives et multiplicatives ;
- démontrer les principales propriétés d'une moyenne mobile centrée ;
- interpréter une moyenne mobile comme un filtre linéaire ;
- analyser le compromis biais-variance lié à la largeur de fenêtre ;
- utiliser lissage exponentiel simple, Holt, Holt-Winters, LOWESS, noyaux et STL ;
- reproduire ces méthodes en Python et comparer leurs résultats.

2.2 Modèle déterministe de tendance

2.2.1 Séparer structure moyenne et fluctuation

Une représentation de base est

$$Y_t = m(t) + \varepsilon_t, \quad t = 1, \dots, n,$$

où :

- $m(t)$ est une fonction déterministe du temps ;
- ε_t est une fluctuation aléatoire centrée.

Si

$$\mathbb{E}[\varepsilon_t] = 0,$$

alors

$$\mathbb{E}[Y_t] = m(t).$$

La tendance est donc ici identifiée à la fonction moyenne.

Attention — tendance observée et tendance théorique

Une courbe lissée calculée sur les données n'est pas la tendance elle-même : c'est un **estimateur** d'une composante théorique inconnue. Deux échantillons issus du même mécanisme peuvent conduire à deux courbes lissées différentes.

2.2.2 Tendance linéaire

Le modèle le plus simple est

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

Lorsque $\beta_1 > 0$, la moyenne augmente linéairement ; lorsque $\beta_1 < 0$, elle diminue.

Exemple — interprétation d'une pente

Si Y_t est une consommation mensuelle et

$$\widehat{Y}_t = 120 + 1.8t,$$

alors le niveau moyen estimé augmente de 1.8 unité par mois, soit environ 21.6 unités par an si la pente reste stable.

2.2.3 Tendance polynomiale

On peut généraliser :

$$m(t) = \beta_0 + \beta_1 t + \beta_2 t^2 + \dots + \beta_p t^p.$$

Ce modèle est **linéaire en paramètres** même s'il est non linéaire en t .

Remarque — extrapolation dangereuse

Un polynôme de degré élevé peut très bien interpoler la période observée et produire des extrapolations absurdes. Un excellent ajustement in-sample ne garantit pas une bonne prévision hors échantillon.

2.3 Moindres carrés ordinaires : dérivation complète




Figure 2.2 – Le degré élevé peut améliorer l’ajustement historique tout en dégradant fortement l’extrapolation.

2.3.1 Formulation matricielle

Écrivons

$$\mathbf{y} = X\beta + \varepsilon,$$

avec

$$\mathbf{y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix}.$$

Pour une tendance polynomiale d’ordre p ,

$$X = \begin{pmatrix} 1 & 1 & 1^2 & \dots & 1^p \\ 1 & 2 & 2^2 & \dots & 2^p \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & n & n^2 & \dots & n^p \end{pmatrix}.$$

Les moindres carrés minimisent

$$Q(\beta) = \|\mathbf{y} - X\beta\|^2 = (\mathbf{y} - X\beta)'(\mathbf{y} - X\beta).$$

Proposition — équations normales

Si X est de rang colonne plein, le minimiseur unique de Q satisfait

$$X'X\hat{\beta} = X'\mathbf{y},$$

et donc

$$\hat{\beta} = (X'X)^{-1}X'\mathbf{y}.$$

Preuve

Développons :

$$Q(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'X'\mathbf{y} + \beta'X'X\beta.$$

Le gradient par rapport à β vaut

$$\nabla_{\beta}Q = -2X'\mathbf{y} + 2X'X\beta.$$

Au point critique,

$$X'X\hat{\beta} = X'\mathbf{y}.$$

Si X est de rang plein, $X'X$ est définie positive et inversible, d'où

$$\hat{\beta} = (X'X)^{-1}X'\mathbf{y}.$$

La Hessienne $2X'X$ est définie positive, donc ce point est l'unique minimum. ■

2.3.2 Cas de la tendance linéaire

Pour

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t,$$

on obtient les formules classiques

$$\hat{\beta}_1 = \frac{\sum_{t=1}^n (t - \bar{t})(Y_t - \bar{Y})}{\sum_{t=1}^n (t - \bar{t})^2},$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{t}.$$

Proposition — centrage du temps

Si l'on remplace t par

$$u_t = t - \bar{t},$$

la pente estimée ne change pas. Seul l'intercept change de paramétrisation.

Preuve

Le numérateur et le dénominateur de $\hat{\beta}_1$ utilisent précisément $t - \bar{t}$. Une translation constante de l'origine temporelle ne modifie donc pas la pente. ■

Conséquence

Centrer le temps améliore souvent la stabilité numérique, surtout pour des polynômes, et rend l'intercept plus interprétable : il devient le niveau estimé

au temps moyen de l'échantillon.

2.4 Propriétés statistiques de l'estimateur MCO

Supposons

$$\mathbf{y} = X\beta + \varepsilon,$$

avec

$$\mathbb{E}[\varepsilon] = 0, \quad \text{Var}(\varepsilon) = \sigma^2 I_n.$$

2.4.1 Absence de biais

Théorème — absence de biais des MCO

Sous ces hypothèses,

$$\mathbb{E}[\hat{\beta}] = \beta.$$

Preuve

$$\hat{\beta} = (X'X)^{-1}X'(X\beta + \varepsilon) = \beta + (X'X)^{-1}X'\varepsilon.$$

En prenant l'espérance,

$$\mathbb{E}[\hat{\beta}] = \beta + (X'X)^{-1}X'\mathbb{E}[\varepsilon] = \beta.$$

■

2.4.2 Matrice de covariance

Proposition — variance des MCO

Sous homoscedasticité et indépendance,

$$\text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}.$$

Preuve

À partir de

$$\hat{\beta} - \beta = (X'X)^{-1}X'\varepsilon,$$

on a

$$\text{Var}(\hat{\beta}) = (X'X)^{-1}X'\text{Var}(\varepsilon)X(X'X)^{-1}.$$

Comme $\text{Var}(\varepsilon) = \sigma^2 I$,

$$\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1} X'X (X'X)^{-1} = \sigma^2 (X'X)^{-1}.$$

■

2.4.3 Estimation de σ^2

Avec k paramètres estimés,

$$\hat{\sigma}^2 = \frac{1}{n-k} \sum_{t=1}^n \hat{\varepsilon}_t^2.$$

Sous normalité et hypothèses classiques, cette quantité permet de construire erreurs standard, tests de Student et intervalles de confiance.

2.4.4 Le problème spécifique des séries temporelles

Shumway et Stoffer insistent sur une limite essentielle : dans une régression temporelle, supposer les erreurs i.i.d. peut être faux. Si

$$\text{Var}(\varepsilon) = \Sigma \neq \sigma^2 I,$$

alors

$$\text{Var}(\hat{\beta}) = (X'X)^{-1} X' \Sigma X (X'X)^{-1}.$$

La formule $\sigma^2 (X'X)^{-1}$ n'est plus correcte.

Attention — significativité artificielle

Une tendance peut apparaître statistiquement « très significative » avec les erreurs standard MCO classiques alors que les résidus sont fortement auto-corrélés. La pente MCO peut rester sans biais sous certaines conditions, mais l'inférence naïve devient trompeuse.

2.5 Projection géométrique et résidus

Définissons la matrice de projection

$$H = X(X'X)^{-1}X'.$$

Alors

$$\hat{\mathbf{y}} = H\mathbf{y}, \quad \hat{\varepsilon} = (I - H)\mathbf{y}.$$

Proposition — orthogonalité des résidus

Les résidus MCO sont orthogonaux aux colonnes de X :

$$X'\hat{\varepsilon} = 0.$$

Preuve

$$X'\hat{\varepsilon} = X'(\mathbf{y} - X\hat{\beta}) = X'\mathbf{y} - X'X\hat{\beta} = 0$$

par les équations normales. ■

Conséquence — somme des résidus

Si le modèle contient une constante, la colonne de 1 appartient à X . L'orthogonalité implique

$$\sum_{t=1}^n \hat{\varepsilon}_t = 0.$$

Cela n'implique cependant **pas** que les résidus soient indépendants, stationnaires ou de type bruit blanc.

2.6 Tendence exponentielle et transformation logarithmique

Supposons

$$Y_t = Ae^{gt}U_t, \quad Y_t > 0,$$

où $U_t > 0$ représente une fluctuation multiplicative.

En logarithmes,

$$\log Y_t = \log A + gt + \log U_t.$$

Le modèle exponentiel devient linéaire sur l'échelle logarithmique.

Attention — retour sur l'échelle originale

En général,

$$\mathbb{E}[e^X] \neq e^{\mathbb{E}[X]}.$$

Ainsi, exponentier une prévision de $\log Y_t$ n'est pas automatiquement une prévision sans biais de Y_t . Sous normalité $X \sim N(\mu, \sigma^2)$,

$$\mathbb{E}[e^X] = e^{\mu + \sigma^2/2}.$$

Preuve

La fonction génératrice des moments d'une normale donne

$$M_X(s) = \exp\left(\mu s + \frac{1}{2}\sigma^2 s^2\right).$$

En prenant $s = 1$,

$$\mathbb{E}[e^X] = M_X(1) = e^{\mu + \sigma^2/2}.$$

■

2.7 Représenter la saisonnalité par variables indicatrices

2.7.1 Modèle saisonnier additif

Pour une série de période s , on peut écrire

$$Y_t = \beta_0 + \beta_1 t + \alpha_{j(t)} + \varepsilon_t,$$

où $j(t) \in \{1, \dots, s\}$ indique la saison.

Par exemple, pour des données trimestrielles :

$$Y_t = \beta_0 + \beta_1 t + \alpha_2 D_{2,t} + \alpha_3 D_{3,t} + \alpha_4 D_{4,t} + \varepsilon_t,$$

le trimestre 1 servant de référence.

2.7.2 Piège des variables indicatrices

Proposition — colinéarité parfaite

Si une constante et les s indicatrices saisonnières sont incluses simultanément, la matrice de design n'est pas de rang plein.

Preuve

À chaque date, exactement une indicatrice vaut 1. Donc

$$D_{1,t} + D_{2,t} + \dots + D_{s,t} = 1.$$

La colonne constante est donc la somme des s colonnes indicatrices : les colonnes sont linéairement dépendantes. ■

Deux solutions

- supprimer une indicatrice et prendre une saison de référence ;

— conserver toutes les indicatrices mais imposer une contrainte comme

$$\sum_{j=1}^s \alpha_j = 0.$$

2.8 Régression harmonique

Une saisonnalité périodique peut aussi être représentée par sinus et cosinus :

$$S_t = \alpha \cos(\omega t) + \beta \sin(\omega t),$$

avec

$$\omega = \frac{2\pi}{s}.$$

Plus généralement,

$$S_t = \sum_{k=1}^K \left[\alpha_k \cos\left(\frac{2\pi kt}{s}\right) + \beta_k \sin\left(\frac{2\pi kt}{s}\right) \right].$$

Proposition — périodicité

Pour tout entier k ,

$$\cos\left(\frac{2\pi k(t+s)}{s}\right) = \cos\left(\frac{2\pi kt}{s}\right),$$

et de même pour le sinus.

Preuve

$$\frac{2\pi k(t+s)}{s} = \frac{2\pi kt}{s} + 2\pi k.$$

Or sinus et cosinus sont invariants par ajout d'un multiple entier de 2π . ■

2.8.1 Forme amplitude-phase

On peut écrire

$$\alpha \cos(\omega t) + \beta \sin(\omega t) = A \cos(\omega t - \varphi),$$

avec

$$A = \sqrt{\alpha^2 + \beta^2}.$$

La phase φ vérifie

$$\cos \varphi = \frac{\alpha}{A}, \quad \sin \varphi = \frac{\beta}{A}.$$

Cette paramétrisation donne une interprétation géométrique de l'amplitude saisonnière.

2.9 Décomposition additive et multiplicative

2.9.1 Modèle additif

$$Y_t = T_t + S_t + R_t.$$

Il convient lorsque l'amplitude saisonnière reste approximativement constante lorsque le niveau change.

2.9.2 Modèle multiplicatif

$$Y_t = T_t S_t R_t, \quad Y_t > 0.$$

Il convient lorsque les fluctuations saisonnières sont proportionnelles au niveau. Après logarithme,

$$\log Y_t = \log T_t + \log S_t + \log R_t.$$

Remarque — décomposition non unique

Sans contraintes supplémentaires, une décomposition n'est pas unique. Dans un modèle additif, si c est une constante,

$$(T_t + c) + (S_t - c) + R_t$$

donne exactement la même série. Les méthodes pratiques imposent donc des conventions de centrage ou de lissage.

2.10 Moyennes mobiles simples et centrées

2.10.1 Moyenne mobile de largeur impaire

Pour $q \geq 1$, une moyenne mobile centrée de largeur $2q + 1$ est

$$M_t = \frac{1}{2q + 1} \sum_{j=-q}^q Y_{t+j}.$$

Elle remplace l'observation courante par une moyenne locale.

2.10.2 Interprétation comme filtre linéaire

Écrivons

$$M_t = \sum_{j=-q}^q w_j Y_{t-j}, \quad w_j = \frac{1}{2q+1}.$$

Les poids satisfont

$$\sum_{j=-q}^q w_j = 1.$$

Proposition — conservation d'une constante

Si $Y_t = c$ pour tout t , alors $M_t = c$.

Preuve

$$M_t = \sum_j w_j c = c \sum_j w_j = c.$$

■

2.10.3 Conservation d'une tendance linéaire par un filtre symétrique

Considérons

$$Y_t = a + bt.$$

Théorème — reproduction des tendances linéaires

Si les poids vérifient

$$\sum_j w_j = 1 \quad \text{et} \quad \sum_j j w_j = 0,$$

alors

$$\sum_j w_j Y_{t-j} = a + bt = Y_t.$$

Preuve

$$\sum_j w_j Y_{t-j} = \sum_j w_j [a + b(t-j)].$$

Donc

$$= a \sum_j w_j + bt \sum_j w_j - b \sum_j j w_j.$$

Avec les deux conditions,

$$= a + bt.$$

■

Conséquence

Une moyenne mobile centrée symétrique ne déforme pas une tendance parfaitement linéaire dans la zone intérieure. Elle réduit en revanche les fluctuations de plus haute fréquence.

2.11 Effet de la moyenne mobile sur un bruit blanc

Supposons

$$Y_t = \mu + \varepsilon_t,$$

avec ε_t indépendants, centrés et de variance σ^2 .

Pour une moyenne mobile de largeur $m = 2q + 1$,

$$M_t = \mu + \frac{1}{m} \sum_{j=-q}^q \varepsilon_{t+j}.$$

Proposition — réduction de variance

$$\text{Var}(M_t) = \frac{\sigma^2}{m}.$$

Preuve

Par indépendance,

$$\text{Var}(M_t) = \frac{1}{m^2} \sum_{j=-q}^q \text{Var}(\varepsilon_{t+j}) = \frac{m\sigma^2}{m^2} = \frac{\sigma^2}{m}.$$

■

Interprétation statistique

Augmenter la fenêtre réduit la variance du bruit, mais peut augmenter le biais si la tendance réelle varie rapidement. C'est une première forme du compromis **biais-variance**.

2.12 Moyenne mobile et élimination d'une saisonnalité

Soit une composante saisonnière de période s telle que

$$S_{t+s} = S_t$$

et




Figure 2.3 – Comparaison de deux largeurs de moyenne mobile centrée.

$$\sum_{j=0}^{s-1} S_{t-j} = 0.$$

Proposition — annihilation par moyenne sur une période complète

La moyenne mobile arrière de longueur s ,

$$M_t = \frac{1}{s} \sum_{j=0}^{s-1} Y_{t-j},$$

élimine exactement la composante S_t si $Y_t = T_t + S_t$ et si T_t est localement constant sur la fenêtre.

Preuve

$$M_t = \frac{1}{s} \sum_{j=0}^{s-1} T_{t-j} + \frac{1}{s} \sum_{j=0}^{s-1} S_{t-j}.$$

Le second terme est nul par hypothèse. Si $T_{t-j} = T_t$ sur la fenêtre, le premier terme vaut T_t . ■

Attention

Dans une vraie série, la tendance n'est pas exactement constante sur la fenêtre. La moyenne mobile produit donc une approximation, pas une séparation parfaite.

2.13 Moyennes mobiles pondérées et noyaux

Un lisseur linéaire général prend la forme

$$\widehat{m}(t) = \sum_{i=1}^n w_i(t) Y_i,$$

avec généralement

$$\sum_i w_i(t) = 1.$$

Dans un lissage par noyau,

$$w_i(t) = \frac{K\left(\frac{t-i}{h}\right)}{\sum_{j=1}^n K\left(\frac{t-j}{h}\right)},$$

où $h > 0$ est la bande passante.

Proposition — conservation des constantes par noyau normalisé

Comme $\sum_i w_i(t) = 1$, une série constante est reproduite exactement.

Remarque — rôle de la bande passante

- petit h : courbe très locale, faible biais mais variance élevée ;
- grand h : courbe plus lisse, variance réduite mais risque de masquer des changements réels.

Shumway et Stoffer présentent le lissage par noyau comme une moyenne mobile pondérée et soulignent précisément ce rôle de la largeur de bande.

2.14 Lissage exponentiel simple

Le lissage exponentiel simple est défini par

$$\ell_t = \alpha Y_t + (1 - \alpha)\ell_{t-1}, \quad 0 < \alpha \leq 1.$$

2.14.1 Forme en moyenne pondérée du passé

Par substitutions successives,

$$\ell_t = \alpha Y_t + \alpha(1 - \alpha)Y_{t-1} + \alpha(1 - \alpha)^2 Y_{t-2} + \dots.$$

Proposition — décroissance géométrique des poids

Le poids de Y_{t-k} vaut

$$\alpha(1 - \alpha)^k.$$

La somme infinie des poids vaut 1 :

$$\sum_{k=0}^{\infty} \alpha(1 - \alpha)^k = \frac{\alpha}{1 - (1 - \alpha)} = 1.$$

Interprétation

- α proche de 1 : réponse rapide, faible lissage ;

— α petit : mémoire longue, fort lissage.

Attention — causalité

Contrairement à une moyenne mobile centrée, le lissage exponentiel ne nécessite pas d'observations futures. Il est donc utilisable en temps réel.

2.15 Méthode de Holt : niveau et tendance locale

Pour une tendance locale, Holt utilise deux équations :

$$\ell_t = \alpha Y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}.$$

La prévision à horizon h est

$$\widehat{Y}_{t+h|t} = \ell_t + hb_t.$$

Remarque

Cette écriture est présentée ici comme outil de lissage. Son interprétation comme modèle probabiliste d'espace d'état sera étudiée plus tard.

2.16 Holt-Winters et saisonnalité

Pour une saisonnalité additive de période s , on utilise un niveau ℓ_t , une pente b_t et une composante saisonnière s_t . Une forme usuelle est

$$\ell_t = \alpha(Y_t - s_{t-s}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1},$$

$$s_t = \gamma(Y_t - \ell_t) + (1 - \gamma)s_{t-s}.$$

La prévision est

$$\widehat{Y}_{t+h|t} = \ell_t + hb_t + s_{t-s+h_s},$$

avec l'indice saisonnier choisi modulo s .

Attention

Les conventions exactes varient selon les logiciels. Il faut toujours vérifier l'initialisation, le type de saisonnalité et la définition de la tendance amortie.




Figure 2.4 - Exemple de lissage local LOWESS.

2.17 LOWESS et régression locale

LOWESS/LOESS remplace un modèle global unique par des régressions ajustées localement autour de chaque date.

Schématiquement, pour estimer $m(t_0)$, on résout

$$\min_{a,b} \sum_{i=1}^n w_i(t_0) [Y_i - a - b(i - t_0)]^2,$$

où les poids décroissent avec la distance entre i et t_0 .

Conséquence

Une régression locale peut suivre des courbures que la droite globale ne capture pas, tout en restant plus stable que l'interpolation exacte des données.

2.18 Splines de lissage

Les splines de lissage recherchent une fonction f minimisant un compromis de la forme

$$\sum_{t=1}^n (Y_t - f(t))^2 + \lambda \int [f''(u)]^2 du.$$

Le premier terme mesure l'ajustement aux données ; le second pénalise la courbure.

Interprétation de λ

- $\lambda \rightarrow 0$: priorité à l'ajustement ;
- $\lambda \rightarrow \infty$: forte pénalisation de la courbure, tendance vers une fonction presque linéaire.




Figure 2.5 – Décomposition STL robuste d’une série mensuelle synthétique.

Remarque

Cette formulation illustre un principe très général en statistique et machine learning :

$$\text{erreur d'ajustement} + \lambda \times \text{complexité}.$$

2.19 STL : décomposition saisonnière robuste

STL signifie *Seasonal and Trend decomposition using Loess*. Elle produit

$$Y_t = T_t + S_t + R_t$$

à partir de lissages locaux successifs.

Ses avantages pratiques sont :

- tendance flexible ;
- saisonnalité pouvant évoluer lentement ;
- option robuste limitant l’influence des valeurs aberrantes ;
- bonne intégration dans statsmodels.

Attention — STL n'est pas un modèle de prévision complet

STL décompose une série. Pour prévoir, il faut spécifier comment extrapoler les composantes ou combiner STL à un modèle de forecasting.

2.20 Biais-variance du lissage

Supposons

$$Y_t = m(t) + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t] = 0.$$

Pour un estimateur $\widehat{m}(t)$,

$$\text{MSE}(\widehat{m}(t)) = \text{Bias}(\widehat{m}(t))^2 + \text{Var}(\widehat{m}(t)).$$

Preuve

Écrivons

$$\widehat{m} - m = (\widehat{m} - \mathbb{E}\widehat{m}) + (\mathbb{E}\widehat{m} - m).$$

En élevant au carré puis en prenant l'espérance, le terme croisé est nul puisque

$$\mathbb{E}[\widehat{m} - \mathbb{E}\widehat{m}] = 0.$$

On obtient donc

$$\mathbb{E}[(\widehat{m} - m)^2] = \text{Var}(\widehat{m}) + (\mathbb{E}\widehat{m} - m)^2.$$

■

Conséquence

Le choix d'une fenêtre, d'une bande passante ou d'un paramètre de lissage est un problème statistique, pas une question esthétique.

2.21 Effets de bord et causalité

Une moyenne mobile centrée nécessite des valeurs avant **et après** t . Près du début et de la fin de l'échantillon, elle n'est donc pas définie sans convention supplémentaire.

Définition — filtre causal

Un filtre est causal à la date t s'il utilise uniquement

$$Y_t, Y_{t-1}, Y_{t-2}, \dots$$

et aucune observation future.

Attention — fuite d'information

Un lisseur centré peut être excellent pour **décrire historiquement** une tendance mais ne doit pas être utilisé comme variable explicative dans une prévision temps réel si sa construction emploie $Y_{t+1}, Y_{t+2}, \dots$

2.22 Exemple analytique intégrateur

Considérons

$$Y_t = 50 + 0.3t + 6 \cos\left(\frac{2\pi t}{12}\right) - 2 \sin\left(\frac{2\pi t}{12}\right) + \varepsilon_t,$$

avec $\varepsilon_t \sim WN(0, 4)$.

2.22.1 Fonction moyenne

$$\mathbb{E}[Y_t] = 50 + 0.3t + 6 \cos\left(\frac{2\pi t}{12}\right) - 2 \sin\left(\frac{2\pi t}{12}\right).$$

2.22.2 Amplitude de la composante harmonique

$$A = \sqrt{6^2 + (-2)^2} = \sqrt{40} \approx 6.325.$$

2.22.3 Variance conditionnelle à la structure déterministe

Puisque seules les innovations sont aléatoires,

$$\text{Var}(Y_t) = 4.$$

2.22.4 Modèle de régression associé

En posant

$$x_{1,t} = t, \quad x_{2,t} = \cos\left(\frac{2\pi t}{12}\right), \quad x_{3,t} = \sin\left(\frac{2\pi t}{12}\right),$$

on obtient une régression linéaire à quatre paramètres.

Conséquence

Une saisonnalité sinusoïdale n'exige pas un modèle non linéaire en paramètres. Elle peut être estimée par MCO.

2.23 Méthode pratique de choix d'un lisseur

Face à une nouvelle série :

1. tracer la série brute ;
2. identifier l'objectif : description historique ou prévision temps réel ;
3. estimer l'échelle temporelle des fluctuations à supprimer ;
4. comparer plusieurs largeurs de fenêtre ;
5. examiner les effets de bord ;
6. vérifier que le lissage ne supprime pas une structure réellement pertinente ;
7. conserver les résidus et les diagnostiquer ;
8. si l'objectif est prédictif, choisir les paramètres sur une validation temporelle et non seulement visuellement.

2.24 Application Python

Le TP associé met en œuvre :

- régression de tendance avec `statsmodels.OLS` ;
- tendance polynomiale ;
- saisonnalité par indicatrices ;
- régression harmonique ;
- moyennes mobiles centrées et causales ;
- vérification Monte-Carlo de la réduction de variance ;
- lissage exponentiel simple ;
- Holt et Holt-Winters ;
- LOWESS ;
- STL ;
- comparaison sur une série macroéconomique disponible dans `statsmodels` ;
- démonstration pratique d'une fuite d'information causée par une moyenne mobile centrée.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm

from statsmodels.tsa.seasonal import STL
from statsmodels.tsa.holtwinters import (
    ExponentialSmoothing,
    Holt,
    SimpleExpSmoothing,
)
from statsmodels.nonparametric.smoothers_lowess import lowess
```

2.25 Erreurs conceptuelles fréquentes

2.25.1 Erreur 1 — assimiler « lisse » à « vrai »

Un lisseur très doux peut être esthétiquement convaincant et statistiquement biaisé.

2.25.2 Erreur 2 — utiliser les tests MCO classiques malgré des résidus autocorrélés

Les erreurs standard naïves supposent une structure qui peut être fausse.

2.25.3 Erreur 3 — sur-ajuster un polynôme

Un degré élevé réduit souvent les résidus in-sample mais peut détruire l'extrapolation.

2.25.4 Erreur 4 — confondre composante saisonnière et moyenne mobile

Une moyenne mobile peut atténuer une saisonnalité, mais elle n'est pas en elle-même un modèle saisonnier.

2.25.5 Erreur 5 — ignorer l'identifiabilité des indicatrices

Constante + toutes les dummies saisonnières conduit à une matrice singulière.

2.25.6 Erreur 6 — oublier la causalité

Une moyenne centrée utilise le futur et ne peut pas être employée naïvement dans un système temps réel.

2.25.7 Erreur 7 — croire que les résidus d'un lissage sont un bruit blanc

Les résidus peuvent contenir autocorrélation, hétéroscédasticité, ruptures ou saisonnalité résiduelle.

2.26 Synthèse du chapitre

Les idées fondamentales sont :

1. la tendance peut être formulée comme une fonction moyenne déterministe ;
2. les MCO sont une projection sur l'espace engendré par les régresseurs ;
3. sous erreurs centrées, homoscédastiques et non corrélées, les MCO sont sans biais et leur covariance vaut $\sigma^2(X'X)^{-1}$;
4. l'autocorrélation des erreurs modifie l'inférence ;
5. une tendance polynomiale reste un modèle linéaire en paramètres ;
6. la saisonnalité peut être représentée par indicatrices ou par fonctions harmoniques ;
7. une décomposition nécessite des conventions d'identification ;
8. une moyenne mobile est un filtre linéaire local ;
9. une moyenne mobile symétrique reproduit exactement les tendances linéaires lorsque ses poids ont moment d'ordre 1 nul ;
10. la variance d'un bruit blanc moyenné sur m observations est divisée par m ;
11. largeur de fenêtre et bande passante contrôlent un compromis biais-variance ;

12. lissage exponentiel, LOWESS, splines et STL offrent des degrés de flexibilité différents ;
13. filtre descriptif et modèle probabiliste ne doivent pas être confondus ;
14. un filtre centré peut provoquer une fuite d'information en prévision.

2.27 Transition vers le chapitre 3

Le présent chapitre a montré **comment extraire** des composantes lisses ou saisonnières. Le chapitre suivant répond à une question complémentaire :

Comment explorer systématiquement une série avant toute décision de modélisation ?

Nous étudierons la qualité de l'index temporel, les données manquantes, les graphiques saisonniers, les lag plots, l'ACF empirique, les transformations, les ruptures et les anomalies.

2.28 Références utilisées pour ce chapitre

- R. H. Shumway & D. S. Stoffer, *Time Series Analysis and Its Applications*, chapitre 2 : régression temporelle, analyse exploratoire, moyennes mobiles, régressions polynomiales et périodiques, lissage par noyau, LOWESS et splines.
- Support officiel du module *Time Series* : ajustement de la tendance et lissage par moyennes mobiles.
- M. El Merouani, *Processus Stochastiques* : tendance, saisonnalité, transformations et rôle du lissage dans la préparation des séries.
- Compléments méthodologiques du cours : dérivations MCO, filtres linéaires, biais-variance et causalité pour la prévision.

2.29 Exercices et problèmes

Les exercices sont classés par niveau : compréhension, calcul, démonstration, Python et études de cas.

2.29.1 Niveau A — Compréhension

Exercice A1 — tendance ou saisonnalité ?

Pour chaque phénomène, indiquer la composante dominante : 1. ventes systématiquement élevées en décembre ; 2. hausse régulière d'une population ; 3. oscillation journalière de température ; 4. ralentissement économique de durée variable.

Exercice A2 — additif ou multiplicatif ?

Une série de ventes passe d'un niveau moyen de 100 à 400 tandis que l'amplitude saisonnière passe de 10 à 40. Quel schéma semble le plus naturel ? Justifier.

Exercice A3 — causal ou non causal ?

Classer : 1. moyenne de Y_t, Y_{t-1}, Y_{t-2} ; 2. moyenne de Y_{t-1}, Y_t, Y_{t+1} ; 3. lissage exponentiel simple.

Exercice A4 — résidus

Pourquoi une bonne droite de tendance ne suffit-elle pas à conclure que les résidus sont un bruit blanc ?

Exercice A5 — dummies saisonnières

Pourquoi ne peut-on pas inclure simultanément une constante et toutes les indicatrices saisonnières sans contrainte ?

2.29.2 Niveau B — Calcul**Exercice B1 — tendance linéaire**

Soit

$$Y_t = 12 + 0.8t + \varepsilon_t, \quad E(\varepsilon_t) = 0.$$

1. Calculer $E(Y_{10})$. 2. Interpréter 0.8. 3. Quelle est l'augmentation attendue entre $t = 10$ et $t = 22$?

Exercice B2 — pente MCO à la main

Pour les données

$$(t, y_t) = (1, 3), (2, 5), (3, 8), (4, 10),$$

calculer $\hat{\beta}_0$ et $\hat{\beta}_1$.

Exercice B3 — tendance quadratique

Pour

$$m(t) = 3 + 2t + 0.5t^2,$$

calculer $m(1), m(2), m(3)$, puis $\Delta m(t)$ et $\Delta^2 m(t)$.

Exercice B4 — amplitude harmonique

Soit

$$S_t = 3 \cos(\omega t) + 4 \sin(\omega t).$$

Déterminer l'amplitude de la sinusoïde équivalente.

Exercice B5 — moyenne mobile

Pour

$$y = (2, 5, 8, 11, 14, 17, 20),$$

calculer les moyennes mobiles centrées de largeur 3.

Exercice B6 — variance après lissage

Un bruit blanc a une variance 25. Quelle est la variance d'une moyenne de 5 observations indépendantes ?

Exercice B7 — lissage exponentiel

Avec $\alpha = 0.3$, $\ell_0 = 100$, $Y_1 = 110$, $Y_2 = 104$, calculer ℓ_1 et ℓ_2 .

Exercice B8 — correction lognormale

Si

$$\log Y \sim N(4, 0.09),$$

calculer $E(Y)$.

2.29.3 Niveau C — Démonstration**Exercice C1 — équations normales**

À partir de

$$Q(\beta) = (y - X\beta)'(y - X\beta),$$

dériver les équations normales.

Exercice C2 — absence de biais

Démontrer $E(\hat{\beta}) = \beta$ sous $E(\varepsilon) = 0$.

Exercice C3 — covariance MCO générale

Montrer que si $\text{Var}(\varepsilon) = \Sigma$, alors

$$\text{Var}(\hat{\beta}) = (X'X)^{-1}X'\Sigma X(X'X)^{-1}.$$

Exercice C4 — orthogonalité

Montrer que $X'\hat{\varepsilon} = 0$.

Exercice C5 — colinéarité saisonnière

Montrer que constante + toutes les dummies de saison donnent une dépendance linéaire.

Exercice C6 — filtre symétrique

Soient des poids w_j tels que

$$\sum_j w_j = 1, \quad \sum_j jw_j = 0.$$

Montrer que le filtre reproduit exactement toute tendance $a + bt$.

Exercice C7 — réduction de variance

Démontrer que la moyenne de m variables indépendantes de variance σ^2 a variance σ^2/m .

Exercice C8 — poids exponentiels

Développer récursivement le lissage exponentiel et montrer que la somme infinie des poids vaut 1.

Exercice C9 — biais-variance

Démontrer

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + Bias(\hat{\theta})^2.$$

Exercice C10 — périodicité harmonique

Montrer que les fonctions $\cos(2\pi kt/s)$ et $\sin(2\pi kt/s)$ ont période s pour $k \in \mathbb{Z}$, avec éventuellement une période fondamentale plus petite.

2.29.4 Niveau D — Python**Exercice D1 — MCO manuels versus statsmodels**

Simuler une tendance linéaire bruitée. Calculer $\hat{\beta}$ par la formule matricielle puis avec `statsmodels.OLS`. Comparer.

Exercice D2 — polynôme sur-ajusté

Simuler une tendance quadratique et ajuster des polynômes de degrés 1, 2, 5 et 10. Comparer erreur in-sample et extrapolation sur 20 dates futures.

Exercice D3 — indicatrices saisonnières

Simuler six ans de données mensuelles avec une saisonnalité fixe. Ajuster une régression avec dummies mensuelles et interpréter les coefficients.

Exercice D4 — régression harmonique

Ajuster une paire sinus/cosinus de période 12 et retrouver numériquement amplitude et phase.

Exercice D5 — Monte-Carlo du lissage

Simuler 5000 bruits blancs de variance 9, lisser par une moyenne de 9 observations et vérifier empiriquement la variance théorique.

Exercice D6 — causalité

Comparer `rolling(window=5, center=True)` et une moyenne arrière. Montrer explicitement quelles observations futures sont utilisées par la version centrée.

Exercice D7 — LOWESS

Simuler une tendance non linéaire et comparer régression quadratique et LOWESS.

Exercice D8 — STL

Construire une série mensuelle avec tendance + saisonnalité + anomalie, appliquer STL robuste et non robuste, puis comparer.

2.29.5 Niveau E — Études de cas**Exercice E1 — PIB trimestriel**

À partir d'une série macroéconomique trimestrielle : 1. tracer le niveau ; 2. ajuster une tendance linéaire puis quadratique ; 3. examiner les résidus ; 4. comparer AIC et comportement hors échantillon ; 5. discuter la validité des erreurs i.i.d.

Exercice E2 — activité mensuelle saisonnière

Pour cinq ans de ventes mensuelles : 1. comparer décomposition additive et logarithmique ; 2. estimer les effets mensuels ; 3. tester une régression harmonique à un puis deux harmoniques ; 4. comparer les courbes ajustées.

Exercice E3 — rapport méthodologique

Rédiger une note de 4 pages expliquant la différence entre : - ajustement de tendance ; - lissage ; - décomposition ; - modélisation probabiliste. Inclure au moins un contre-exemple où un lisseur visuellement convaincant laisse des résidus très autocorrélés.